Preparação das radiografias

Relatório de pré-processamento e organização das imagens

Fonte e definição da tarefa

O estudo usa a ChestMNIST 64, uma versão pública e reduzida das radiografias de tórax do NIH ChestXray14. A demonstração simula o uso de um assistente, com radiografias reais da base e rótulos extraídos automaticamente de relatórios radiológicos. A tarefa binária usa apenas a coluna de cardiomegalia. Um exame sem esse rótulo pode ter outras alterações.

Pipeline de preparação

1. Obtenção e integridade. O notebook baixa o arquivo NPZ oficial, compara o MD5 com o valor publicado e carrega as imagens e os rótulos de cada partição.

2. Conversão e tamanho. As matrizes em escala de cinza são convertidas para RGB com três canais iguais. A entrada final mede 56 × 56 pixels. O pipeline preserva a proporção e aplica preenchimento se receber uma imagem de dimensões diferentes. A distribuição de origem vem redimensionada de 1024 × 1024 para 64 × 64.

3. Normalização. A CNN simples recebe tensores float32 no intervalo [0, 1]. Para a ResNet18, aplicamos também as médias e desvios por canal do ImageNet. A resolução reduzida permite repetir o treinamento em ambiente acadêmico com menor custo computacional.

Partições e prevenção de vazamento

As partições oficiais são preservadas. Com a semente 42, o treino reúne os positivos e quatro negativos por positivo. A validação parte de 8.000 exames aleatórios. O teste usa o restante da partição oficial após excluir os 8.000 exames da primeira avaliação e as suas cópias exatas. Validação e teste mantêm o desbalanceamento natural, que é relevante para interpretar a precisão. Removemos duplicatas exatas por SHA-256, com prioridade para treino, validação e teste, nessa ordem. A validação orienta a escolha da época e do limiar. O teste tem 392 positivos.

Partição	Total oficial	Exames usados	Com rótulo	Sem rótulo
Treino	78468	9750	1950	7800
Validação	11219	7997	179	7818
Teste	22433	14432	392	14040

Limites de interpretação

A resolução reduzida limita detalhes anatômicos, e o NPZ não fornece identificadores para auditar a separação por paciente. Os rótulos da fonte são imperfeitos e o teste é interno à mesma base. Os resultados descrevem uma classificação experimental com uso acadêmico.

Fonte: MedMNIST · Distribuição oficial no Zenodo · Licença CC BY 4.0